

前回の復習問題（1/2）

1. 引用と剽窃の相違は何でしょうか？また，レポートに論文等から引用する際には，どう記載すればよいでしょうか？

- 「自分の文章と見せかけるか？」が大きい相違ですね。記載法は直接引用，間接引用の方法を示せば良いと思います。

2. 何か自分の気になる（看護，医療に関わる）疑問をPICO（PECO）に整理してみましょう。

- シンプルに整理できたでしょうか？このステップができれば，研究への入口にたどり着いたことになります。

前回の復習問題 (2/2)

3. 次のうち，調査結果の一般化可能性に疑問が生じるのはどれでしょう？
また，なぜでしょう？

1. ワクチンの臨床試験に参加してくれた人をランダムに群分けして，ワクチン接種と非接種の群を設定して比較した。比較可能性は保証されますが，試験への参加の偏りについては気になりますので，一般化可能性には注意が必要です。
2. 糖尿病発症に関連する要因を探るため，外来で糖尿病治療中の患者に過去の食習慣，運動習慣を聴取した。「患者」が偏っていなければ一般化可能性あり，です。
3. スマートフォンの1日の利用時間について，インターネット上でアンケート調査した。これは明らかに疑問ありですね。偏った集団を調べている可能性が高いので。
4. 通院してがんの放射線治療中の患者5名に生活上の困難点を聴取した。少数で偏っていますが，質的研究の初期の段階では一般化可能性を論じることはありません（選択肢としては微妙でした）

第11回

統計データ解析(1) 確率・統計の考え方

第11回の要点（とテキスト対応範囲）

【授業の到達目標】

統計学の前提となる確率や統計学の基本概念を理解し，説明できる
（実践は情報科学演習で）

- なぜ，看護職に確率・統計の知識が必要か？
 - EBN実践ため，業務関連データの整理のため
- 統計学の基本概念
 - 記述統計と推測統計
- 確率の基本
 - 順列，組み合わせ
 - 基本的な定理
 - 条件つき確率と“独立・従属”
 - 確率分布の例（二項分布）

なぜ統計学が必要か？

経験や慣習ではなく、科学的根拠に基づいて看護実践を行う
→ Evidence Based Nursing (p.54)

・科学的根拠（エビデンス）とは
ある事柄を証明するための「客観的で信頼性の高い証拠」
→（適切な方法で計測された）データから得られた知見

エビデンスのレベル

1. 意見・報告
2. 症例報告
3. 統計的な検証のある報告
4. ランダム化比較試験

} 統計学の知識が必要！

モデル化

- 現実複雑だが、とりあえず単純な数学の問題に置き換える
- 「高血圧の患者が2割含まれる集団から10人を調べたら、患者が何人含まれるか」
= 「赤い玉と白い玉が2 : 8の比で大量に入っている壺から10個玉を取り出したら、赤い玉がいくつ含まれるか」
- 「喫煙は肺がんを5倍増やす。では喫煙率を40%から10%に減らすことができたなら、肺がんをどれだけ減らせるか」
(範囲としては疫学ですが)

記述統計と推測統計

• 記述統計

- 観察された**標本**における統計データの要約
 - 分かりやすく、適切に“情報を圧縮”

• 推測統計

- 標本における統計データから、**母集団**について推測
 - 推測において、“確からしさ”の程度が必要
- 「母集団」と「標本」については13回に補足
- 第10回の「一般化可能性（外的妥当性）」が前提



確率の基本

- 順列, 組み合わせ
- 基本的な定理
- 条件つき確率と“独立・従属”
- 確率分布の例 (二項分布)

樹形図

ある事柄の場合の数を調べるために書いた、
順に枝分かれしていく図を樹形図という。

例：3回コインを投げたときの表と裏の出方の場合の数



場合の数の法則

Aの起こり方がa通り, Bの起こり方がb通りなら

和の法則:

2つの事柄A, Bは同時には起こらないとする.

AまたはBのどちらかが起こる場合はa+b通り.

積の法則:

AとBがともに起こる場合はa × b通り.

順列

順序をつけて1列に並べる配列を順列という.


異なる n 個から r 個を取り出して並べる順列の総数は ${}_nP_r$ である. ただし $(r \leq n)$

$${}_nP_r = n(n-1) \times \cdots \times (n-r+2)(n-r+1)$$

$$\text{特に, } {}_nP_n = n(n-1) \times \cdots \times 2 \times 1 = n!,$$

$$0! = 1, {}_nP_0 = 1$$

例) A, B, C, D, Eと書かれたカードが5枚ある.
このとき5枚の中から2枚選んで並べるとき場合の数は



$$5 \times 4 = 20 \text{通り}$$


順列の特別な場合：円順列

配列を円形に並べたものを円順列という。
ただし、円順列では、回転して重なるものは
同じ並び方と考える。

$$\text{数え方} : \frac{{}_nP_n}{n} = (n-1)!$$

円順列

例：A, B, C, Dの4人が円卓に座るとき, 並び方は何通りあるか



3つの席をB, C, Dの3人で順番に選ぶ

B:3通り

C:2通り

D:余り

$$(4 - 1)! = 3! = 6$$


順列の特別な場合：重複順列

異なるものの中から重複を許して取り出して並べる順列を重複順列という.

数え方： n^r

重複順列

例：5個の文字a, b, c, d, eから重複を許して2個取り出して1列に並べるとき何通りか



$$5^2 = 25 \text{通り}$$

組み合わせ

異なるもののの中から異なるいくつかのものを
取り出し、順序は問題にしないで、1組にした
ものを組み合わせという。

$${}_nC_r = \frac{{}_nP_r}{r!} = \frac{n!}{r!(n-r)!}$$

組み合わせ

例：男子5人, 女子4人のサークルから男子2人, 女子2人を選ぶ組み合わせは何通りか

$${}_5C_2 \times {}_4C_2 = \frac{5 \cdot 4}{2 \cdot 1} \times \frac{4 \cdot 3}{2 \cdot 1} = 60$$

演習問題

A～Hの8文字のカードがある.

1. 3つの文字を選んで並べるときの順列の総数を求めよ.
2. 3つの文字を選ぶときの組み合わせの総数を求めよ.
3. 5つの文字を選ぶときの組み合わせの総数を求めよ.

演習問題

1. ${}_8P_3 = 336$

2. ${}_8C_3 = 56$

3. ${}_8C_5 = 56$

集合

集合とは、いくつかのものをひとまとめにして考えたものの集まりのことである。

- 例)
- ・ 自然数全体の集まり $\rightarrow 1, 2, 3, \dots$
 - ・ $x^2 + y^2 < 1$ を満たす平面上の点 (x, y) 全体の集まり
 $\rightarrow$ 半径1の円の内部
 - ・ アルファベットの集まり $\rightarrow A, B, C, \dots, Z$

➡ 数や点，文字などの範囲のはっきりしたものの集まり

※範囲がはっきりしないものの集まりは集合とは考えられない

例) 十分大きい自然数の集まりは？ $\rightarrow$ 十分大きいとは？

ある集合 A に含まれるものを A の元あるいは要素という.

例) 一桁の自然数の集まり $(1, 2, \dots, 9)$ を X とすると
集合 X は $1, 2, \dots, 9$ を要素とする.

また集合 X を

$$X = \{1, 2, 3, 4, 5, 6, 7, 8, 9\}$$

あるいは

$$X = \{x \mid 1 \leq x < 10, x \text{は自然数}\} \quad \text{と表す.}$$

元を一つも含まないような集合を空集合といい,
 $\emptyset$ で表す.

集合の元（要素）

a が集合 A の元であることを

$$a \in A \quad \text{または} \quad A \ni a$$

a が集合 A の元でないことを

$$a \notin A \text{または} A \not\ni a \quad \text{と表す.}$$

ある集合 A, B が全く同じ元からなるとき, 等しいといい

$$A = B \quad \text{と表す.}$$

例) $A = \{x | x \text{は} 2 < x < 10, x \text{は素数}\}, B = \{x | 1 < x < 8, x \text{は奇数}\}$

$$A = \{3, 5, 7\}, \quad B = \{3, 5, 7\}$$

部分集合

集合 A, B について A のすべての元が B の元でもあるならば
すなわち, 任意のものの x について

$$x \in A \Rightarrow x \in B$$

が正しいならば, A は B の部分集合であるといい,

$$A \subset B \text{ と書く.}$$

その否定 (A のすべての元が B の元でない) は

$$A \not\subset B \text{ で表す.}$$

例) $A = \{3, 5, 7\}, B = \{1, 3, 5, 7, 9\}$ とすると


A のすべての元 ($3, 5, 7$) は B の元でもあるから $A \subset B$

集合の間の演算

- 和集合：2つの集合 A, B について A の元と B の元を全てよせ集めて得られる集合を A と B の和集合といい,
 $A \cup B$ と表す.

例) $A = \{1, 3, 5, 7, 9\}, B = \{2, 3, 5, 7\}$ とすると

$$A \cup B = \{1, 2, 3, 5, 7, 9\}$$



- 共通部分


2つの集合 A, B について A, B の共通の元全体の集合を
 A と B の共通部分といい,

$A \cap B$ と表す.

例) $A = \{1, 3, 5, 7, 9\}, B = \{2, 3, 5, 7\}$ とすると
 $A \cap B = \{3, 5, 7\}$

例) $A = \{x | \text{正の偶数全体}\},$
 $B = \{x | \text{正の奇数全体}\}$ とすると
 $A \cap B = \emptyset$

$A \cap B = \emptyset$ のとき A, B は互いに素であるという.



ド・モルガンの法則

集合 A, B に対して, 以下の関係が成り立つ.

- $\overline{A \cup B} = \bar{A} \cap \bar{B}$

A と B の和集合の補集合は A の補集合と B の補集合の共通部分と等しい.

- $\overline{A \cap B} = \bar{A} \cup \bar{B}$

A と B の共通部分の補集合は A の補集合と B の補集合の和集合と等しい.

演習問題

全体集合 $U = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$,

$X = \{x \mid x \text{ は } 10 \text{ より小さい正の素数である}\}$,

$Y = \{y \mid y \text{ は } 1 \leq y \leq 10 \text{ であるような偶数である}\}$

以下の問いに答えよ.

(1) $X \cup Y$

(2) $X \cap Y$

(3) $\overline{X \cap Y}$

演習問題

$$U = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\},$$

$$X = \{x \mid x \text{は} 10 \text{より小さい正の素数である}\}$$

$$X = \{2, 3, 5, 7\}, \bar{X} = \{1, 4, 6, 8, 9, 10\}$$

$$Y = \{y \mid y \text{は} 1 \leq y \leq 10 \text{であるような偶数である}\}$$

$$Y = \{2, 4, 6, 8, 10\}, \bar{Y} = \{1, 3, 5, 7, 9\}$$

$$(1) X \cup Y = \{2, 3, 4, 5, 6, 7, 8, 10\}$$

$$(2) X \cap Y = \{2\}$$

$$(3) \overline{X \cap Y} = \bar{X} \cup \bar{Y} = \{1, 9\}$$

場合の数・確率

確率とは

確率：

ある事柄が起こることが期待される程度を表す数値.

試行と事象：

同じ状態で繰り返すことができ、その結果が偶然によって決まる実験や観測などを試行といい、試行の結果起こる事柄を事象という.

例：サイコロを振ったら1の目が出た

試行

事象

確率とは

試行によって起こりうるすべての事柄を全事象あるいは標本空間といい, U や Ω で表す.

このとき U は事象を元にもつ集合である.

例) サイコロを1回投げたとき,

全事象 (標本空間) : $\Omega = \{1, 2, 3, 4, 5, 6\}$ で表す.

- ・ “2の目が出る” という事象は $\{2\}$
- ・ “奇数の目が出る” という事象は $\{1, 3, 5\}$

→ 事象は全事象の部分集合となる.

(高校までの)確率

事象Aが起こる確率

$$P(A) = \frac{n(A)}{n(\Omega)}$$


$n(A)$: 事象Aが起こる場合の数
(部分集合の元の数)

$n(\Omega)$: 起こりうるすべての場合の数
(全事象の元の数)

確率の基本性質

和事象：


“事象AまたはBが起こる”という事象をAとBの和事象といい, $A \cup B$ で表す.



例) サイコロを1回投げたとき,
全事象 (標本空間) : $\Omega = \{1, 2, 3, 4, 5, 6\}$.

- $A = \{2\}$: “2の目が出る”という事象
- $B = \{1, 3, 5\}$: “奇数の目が出る”という事象 とすると


$$A \cup B = \{1, 2, 3, 5\}$$



確率の基本性質


積事象：

“事象AとBがともに起こる”という事象をAとBの積事象といい, $A \cap B$ で表す.




例) サイコロを1回投げたとき,
全事象 (標本空間) : $\Omega = \{1, 2, 3, 4, 5, 6\}$.

- $A = \{3\}$: “3の目が出る”という事象
- $B = \{1, 3, 5\}$: “奇数の目が出る”という事象 とすると




確率の基本性質

$A \cap B = \emptyset$ のとき, AとBは互いに排反である.



例) サイコロを1回投げたとき,
全事象 (標本空間) : $\Omega = \{1, 2, 3, 4, 5, 6\}$.

- $A = \{2\}$: “2の目が出る”という事象
- $B = \{1, 3, 5\}$: “奇数の目が出る”という事象 とすると



確率の基本性質

1. 任意の事象 A に対して $0 \leq P(A) \leq 1$

$$P(\emptyset) = 0, P(U) = 1$$

2. 2つの事象 A, B がお互いに排反であるとき

$$P(A \cup B) = P(A) + P(B)$$

排反でないとき（加法定理）

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$


余事象の確率

余事象 A^c :

全事象 Ω とする. A が起こらないという事象を A の余事象といい, $\overline{A}$, A^c で表す.

余事象の確率:

$$P(A^c) = 1 - P(A)$$



独立な試行の確率

独立な試行: 2つの試行が互いに他方の結果に影響を及ぼさないとき, これらの試行は独立であるという.

$$P(X \cap Y) = P(X) \times P(Y)$$

例) X :サイコロを振る, Y :コインを投げる $\Rightarrow X, Y$ は独立

$$P(X = 6 \cap Y = 1) = \frac{1}{6} \times \frac{1}{2} = \frac{1}{12}$$

独立と従属

独立な試行: 2つの試行が互いに他方の結果に影響を及ぼさないとき, これらの試行は独立であるという.
一方の結果に依って片方の結果が変化するとき、従属であるという.

事象AとBが独立ならば,

$$P(A \cap B) = P(A) \times P(B)$$

事象AとBが独立でない(=従属)ならば,

$$P(A \cap B) = P(A)P(B|A)$$

条件付き確率

条件付き確率:

2つの事象A, Bについて, Aが起こったときに, B
が起こる確率を条件付き確率といい,

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

で表す.

例)10本のくじの中に当たりくじが2本ある。

Aが当たりを引いた後、くじを戻さずに、Bがくじを引くとき、
A, Bが両方とも当たりを引く確率

A: Aが当たりを引く事象

B: Bが当たりを引く事象とすると

$P(A \cap B)$ = A, Bが両方とも当たりを引く確率

$P(B|A)$ = Aが当たりを引いた後、Bが当たりを引く確率

このときBはAに従属なので

$$\begin{aligned} P(A \cap B) &= P(A)P(B|A) \\ &= \frac{2}{10} \times \frac{1}{9} = \frac{1}{45}. \end{aligned}$$

ベイズの定理

$$\begin{aligned} P(A|B) &= \frac{P(A)P(B|A)}{P(B)} \\ &= \frac{P(A)P(B|A)}{P(B|A)P(A) + P(B|A^c)P(A^c)} \end{aligned}$$

$$\begin{aligned} \because P(A|B) &= \frac{P(A \cap B)}{P(B)} \Leftrightarrow P(A \cap B) = P(B) \times P(A|B), \\ P(B|A) &= \frac{P(A \cap B)}{P(A)} = \frac{P(B) \times P(A|B)}{P(A)} \end{aligned}$$

ベイズの定理の（ここでの）意義

- 原因の有無によって結果の起こりやすさが異なる場合
- ある結果が観察された
（原因の有無の割合が分かっている）
- どちらの原因で起きたか、確率が分かる
- 「原因→結果」の確率から「結果→原因」の確率に変換できる

具体例 ～ 陽性反応的中度

- ある人（病気かどうかは不明）が、がんの検査Xを受け、陽性となった場合に、本当に罹患している確率は

- 感染者が検査Xで陽性になる確率
 - $P(\text{検査で陽性}|\text{罹患}) = \text{敏感度} = 0.90$
- 健康な人(非罹患)が、陽性になる確率
 - $P(\text{検査で陽性}|\text{非罹患}) = \text{偽陽性} = 0.02$

集団においてがん罹患している割合が1%とすると、

$$P(\text{罹患} | \text{検査で陽性}) = \frac{(0.01 \times 0.90)}{(0.90 \times 0.01) + (0.02 \times 0.99)} = 0.3125$$

陽性反応的中度自体は、この科目の試験には出題しません

陽性反応的中度の簡単な例

- 確率で考えるより，“人数”で考えると楽
- 1,000人の住民が居ます。その中の1%ががんを罹患しています。ある検査を用いると，がん患者の90%が陽性になります。しかし，がんでない人からも2%の陽性が出現します。
- つまり，1,000人中10人の患者から，9人の陽性者。990人の非患者から約20人の陽性（偽陽性）が出現。つまり，陽性となった29人中9人が本当のがん患者。
- 陽性反応的中度 $\div 9 \div 29 = 0.31$, 約31%

演習問題

研究室には12人学生がいて, 7人は男子で5人は女子である. この中から研究発表をする4人を選ぶとき, 次の確率を求めよ. ただし一人1回しか発表しないものとする.

1. 選ばれたのは全て女子である.
2. 男子が3人, 女子が1人選ばれる.
3. 少なくとも1人は男子が選ばれる.

反復試行の確率

同じ条件のもとで同じ試行を繰り返し行うような試行を反復試行という.

反復試行の確率:

1回の試行で事象Aが起こる確率を p とすると,
この試行を n 回繰り返すときAが r 回起こる確率は,

$${}_nC_rp^r(1-p)^{n-r}$$

→ Aが起こる回数ごとに表にしたものを確率分布という
(詳しくは次回)

例) サイコロを10回投げて、6が3回出る事象をBとすると、 $P(B)$ は？

サイコロを1回投げたとき、

全事象（標本空間）： $\Omega = \{1, 2, 3, 4, 5, 6\}$.

$A = \{6\}$: “6の目が出る”という事象

$$P(A) = \frac{1}{6}$$

$A^c = \{1, 2, 3, 4, 5\}$: “6以外の目が出る”という事象

$$P(A^c) = 1 - \frac{1}{6} = \frac{5}{6}.$$

$$P(B) = {}_{10}C_3 P(A)^3 \cdot P(A^c)^7 = \frac{10 \cdot 9 \cdot 8}{3 \cdot 2 \cdot 1} \left(\frac{1}{6}\right)^3 \left(\frac{5}{6}\right)^7 = \frac{20 \cdot 5^7}{6^9}$$

演習問題

12人の中から4人を選ぶ： ${}_{12}C_4$ 通り

1. 女子5人から4人を選ぶ ${}_5C_4$
2. 男子7人から3人, 女子5人から1人を選ぶ
 ${}_7C_3 \times {}_5C_1$
3. 少なくとも1人男子 $\Leftrightarrow 1 - (\text{全員女子である確率})$

(おまけ) 高校までの確率の定義

- ・ 確率の定義 (ラプラス流)


$$\begin{aligned} (\text{確率}) &= \frac{(\text{対象となる場合の数})}{(\text{起こりうる全ての場合の数})} \\ &= \frac{(\text{事象の元の数})}{(\text{標本空間の元の数})} \end{aligned}$$



P. S. Laplace(1749-1827)

ラプラス流では求められない確率

- ・ ダーツを投げて赤いところに当たる確率は？



ラプラス流で求めると

$$\begin{aligned} P(\text{赤い部分に矢が刺さる}) &= \frac{(\text{事象の元の数})}{(\text{標本空間の元の数})} \\ &= \frac{(\text{的の赤い部分の座標の数})}{(\text{的の全ての座標の数})} \end{aligned}$$

数学的には座標の数は無限個存在するので

$$P(\text{赤い部分に矢が刺さる}) \rightarrow \frac{\infty}{\infty} (\text{不定形})$$



ラプラス流では確率を定義できない！


任意の事象 A に対して実数に対応させる関数 $P(\cdot)$ で次の3つの性質を満たすものを確率という

確率の公理（コルモゴロフ流）

(P1) 全ての事象 A に対して $0 \leq P(A) \leq 1$



(P2) $P(\Omega) = 1$

(P3) 互いに排反な事象 $A_1 \cap A_2 = \emptyset$ に対し,
$$P(A_1 \cup A_2) = P(A_1) + P(A_2)$$



アンドレイ・ニコラエヴィッチ・
コルモゴロフ(1903-1987)

- ・ ダーツを投げて赤いところに当たる確率は？

全事象 Ω : 的  の座標の集合 可測集合 A :  の座標の集合

事象 A に対して実数に対応させる関数 $P(A) = (Aの面積)/(的の面積)$ とすると

(P1) $0 \leq P(A) \leq 1$

(P2) $P(\Omega) = 1$

(P3) 互いに排反な（重なりがない）事象 $A_1, A_2, A_3, \dots$ があるとき、それらの和集合の確率は、個々の確率の和と等しい。

➡ 確率の公理を満たす！（ $P(A) = 1/4$ と計算できる）

第12回

統計データ解析(2) 記述統計

第12回の要点（とテキスト対応範囲）

【授業の到達目標】

記述統計の手法の主要なものを説明できる（実践は情報科学演習で）

- 統計データの種類
 - 量的尺度，質的尺度
- 度数分布とグラフ表現
- データ要約（記述）の方法
 - 質的データ
 - 量的データ：代表値，散布度，パーセンタイル
 - 2変数を組み合わせた記述

統計データ（を測る尺度）の種類

量的データ p264	質的データ p260
【比尺度】 身長cm，体重kg，・・・ など，一般に単位を持ち，値0が「本当にその特性が0」を意味する ＝「2倍の体重」など比を使える	【順序尺度】 尿蛋白（－，±，＋＋，＋＋＋）， 何かの頻度（いつも，時々，めったに）， など，限られた個数で，順序性のある値をとる
【間隔尺度】 摂氏温度（℃），試験の点，・・・ など，ほぼ比尺度と同様に扱えるが， 値0が「本当の0」とは考えられない ＝差は「10点高い」など計算できる	【名義尺度】 ABO式血液型，性別，・・・ など，限られた個数で，順序性のない値をとる

尺度に関する補足

- 連続量，離散量という区分
 - 量的データでも
 - 連続：「重さ」，「長さ」などは（測定上の細かさは別にして）本来は，いくらでも細かくはかれる＝連続している値をとる場合
 - 離散：「発作の回数」，「子どもの数」など，とびとびの（通常は0以上の整数）値しかとらない場合
- 質的データの値
 - “「男」，「女」”とか，“A,B,O,AB”とか取り得る値の区分はカテゴリ（“ー”は省略が望ましい）
 - 順序尺度はカテゴリの併合時に注意（p260）
 - 各カテゴリの「男」などの値をラベル，と呼ぶ
 - データ処理上は「男」＝1，「女」＝2など，コード化する（p251）
- データ（尺度）の変換
 - 量的→順序→名義 の方向へ変換は可能
 - 例えば，肥満度（BMI）を肥満判定（肥満，正常，るいそう）へ

度数分布とグラフ表現

- 平均などを計算する前に、分布を表やグラフで確認ことが大事
 - 変なデータが紛れていないかチェック
 - 自分で入力したデータは特に注意！
 - データの分布を観察して、使いたい統計手法に適しているかチェック
 - ※分布：どれくらいの値にあつまり、どの範囲に広がっているか、など
 - 正規分布（後出）など、特定の分布を前提とした統計手法あり
 - 分布自体が、重要なエビデンス
 - 例えば「基準（標準）値の範囲」を示す、「手術後の5年生存率」を報告する、など

度数分布表を作る ①質的データ

- 例：新生児20人のABO式血液型

No.	血液型	No.	血液型	No.	血液型	No.	血液型
1	A	6	A	11	B	16	O
2	AB	7	A	12	A	17	AB
3	O	8	A	13	O	18	B
4	O	9	O	14	AB	19	O
5	B	10	A	15	B	20	A

- 各カテゴリの度数（人数）を数え上げる

値（血液型）	A	B	O	AB	計
度数（人）					
相対度数（%）					

度数分布表を作る ①質的データ

- 例：新生児20人のABO式血液型

No.	血液型	No.	血液型	No.	血液型	No.	血液型
1	A	6	A	11	B	16	O
2	AB	7	A	12	A	17	AB
3	O	8	A	13	O	18	B
4	O	9	O	14	AB	19	O
5	B	10	A	15	B	20	A

- 各カテゴリの度数（人数）を数え上げる

値（血液型）	A	B	O	AB	計
度数（人）	7	4	6	3	20
相対度数（%）	35.0	20.0	30.0	15.0	100

度数分布表を作る ②量的データ

(p268)

- 例：女子中学生50名の血清総コレステロール値(mg/dl)

130	140	141	143	144	145	145	145	145	149
150	154	155	155	157	158	159	161	161	161
161	162	163	163	166	166	168	169	169	171
171	174	175	176	176	176	177	184	184	189
191	193	199	201	202	208	213	218	221	233

- 値を区切って（階級を作成し）範囲内の度数（人数）を数え上げる

130	140	141	143	144	145	145	145	145	149
150	154	155	155	157	158	159	161	161	161
161	162	163	163	166	166	168	169	169	171
171	174	175	176	176	176	177	184	184	189
191	193	199	201	202	208	213	218	221	233

血清コレステロール値
(mg/dl)

度数（人）

相対度数
(%)



累積相対度数
(%)

※階級は、通常 “XX以上YY未満”を“XX～YY”と表記することが多い

130～140	1	2.0	2.0
140～150	9	18.0	20.0
150～160	7	14.0	34.0
160～170	12	24.0	58.0
170～180	8	16.0	74.0
180～190	3	6.0	80.0
190～200	3	6.0	86.0
200～210	3	6.0	92.0
210～220	2	4.0	96.0
220～以上	2	4.0	100.0
計	50	100.0	100.0


度数分布表からグラフへ①

- エクセルによるグラフ作成は演習で
- 「血液型」の例
 - タイトルや凡例など仕上げは甘いですが
 - 「円グラフ」は“視覚的に誤解を生む可能性が高い”と、統計学の専門家は好みませんが



度数分布表からグラフへ②


- 通常のはistogram（上）の他に，累積（相対）度数のグラフ（下）も有効
 - 例えば，“ある値以上の割合”が読み取りやすい



その他のグラフ表現

• 箱ひげ図

- グループ毎に分布を簡潔に表示できる



• 幹葉表示

- 文字の並びでヒストグラムとして眺められる
- かつ、元のデータが読み取れる

13*	0
14*	013455559
15*	0455789
16*	111123366788
17*	11456667
18*	449
19*	139
20*	128
21*	38
22*	1
23*	3

データの要約（記述）の方法


度数分布を確認したら

- 1 変数ごとの要約（単純集計）
 - 質的変数：割合，最頻値，（順序尺度なら）中央値
 - 量的変数
 - 代表値（平均値，中央値，最頻値）
 - 散布度（分散，標準偏差）
 - 範囲（最大値，最小値），パーセンタイル，四分位数
- 2 変数を組み合わせた記述（関連性の分析）
 - 質的変数×質的変数：クロス集計表
 - 量的変数×量的変数：散布図，相関係数，回帰直線
 - 質的×量的は“示したいこと”のパターンによって様々→推測統計パートで紹介


代表値

- 平均値(mean, average)
 - 総和をデータの個数で割る
 - 量的尺度のデータで利用可能
- 中央値 (median)
 - データを順に並べた（ソートした）とき，中央になる値
 - 量的尺度，順序尺度で利用可能
 - 第2四分位数，50パーセンタイル値でもある
- 最頻値 (mode)
 - もっとも“よく出てくる”値
 - すべての尺度で利用可能


130	140	141	143	144	145	145	145	145	149
150	154	155	155	157	158	159	161	161	161
161	162	163	163	166	166	168	169	169	171
171	174	175	176	176	176	177	184	184	189
191	193	199	201	202	208	213	218	221	233



- 平均値 170.3mg/dL
- 中央値 166mg/dL
- 最頻値 165mg/dL (ヒストグラムで最も度数の多い階級の中心)



左右対称なら 3 つの代表値は一致するが



最頻値について

- 量的データの場合は、「まったく同じ値」をカウントするのではなく、度数分布表で最も度数が多い「階級」を見つけることになる
 - 最頻値（の階級）が複数なら、1つに定まらない
 - 階級の区切り方で、同じデータでも最頻値が変化する
- 代表値として有効なこともあります
- 最大の“使いづらさ”は、推測統計で（ほぼ）使えない点
→次回以降、出てきません

補足：興味のある方はどうぞ

- 代表値はあくまで“集団レベル”で、そのデータを個人（がん患者）として、どう受け止め、どう考えたか（といった内容）。すぐれた文章です。
- Stephen Jay Gould、「The Median Isn't the Message（メジアンはメッセージではない）」、早川書房「がんばれカミナリ竜」収録
- 下記のサイト（英語）で読めます
 - <https://journalofethics.ama-assn.org/article/median-isnt-message/2013-01>



分散, 標準偏差 : ※使えるのは量的データだけ

- ばらつきの考え方の基本

- 一つ一つのデータが
「平均値（代表値）から、どれだけ離れているか」を「**偏差**」
- 例えば「平均点70のテストで私は60点」 = 偏差は-10点

- 全例の偏差をまとめれば、全体のばらつきの指標だが


1. 偏差の総計は、必ず0 （平均値の性質から自明）, そこで
2. 「偏差の二乗の合計」をデータの個数で割る → 「**分散**」
3. 分散の平方根を求める → 「**標準偏差**」

- 通常, 集計時には, (データの個数-1) で割った「**不偏分散**」とその平方根「**標本標準偏差**」を使います。理由は次回。


標準偏差の利用

- 「平均値 ± 標準偏差」形式の表現
 - 例えば “身長 170.0 ± 5.0 cm”
 - データが正規分布（次回紹介）していれば，分布全体が表現できる
 - 例えば “身長 170.0 ± 5.0 cm”なら，身長180cm以上は全体の2%ちょっと，とか
 - 各データについて， $10 \times \{ (\text{個人の得点} - \text{平均値}) \div \text{標準偏差} \} + 50$ と変換すれば「偏差値」
- 同じ種類のデータ（例えば国語と算数の試験）なら
 - 標準偏差（や分散）が大きい方が，ばらつきが大きいと分かる
 - 異なる種類，異なる平均値の変数でばらつきを比較したい場合，比尺度なら変動係数を利用


- 代表値は，分布の位置を 1 点で示す



- 標準偏差は，分布の広がり（ばらつき）を1つの数値で示す



四分位, 最小値・最大値 (範囲)




※**範囲** (最大値 - 最小値) は, どんなにデータの個数が多くても, 両端の2例だけで決まってしまう

パーセンタイルの利用

<お子さんの体重や身長をこのグラフに記入しましょう。>

女の子 幼児身体発育曲線 (平成22年調査)



身長と体重のグラフ：帯の中には、各月・年齢の94パーセントの子どもの値が入ります。乳幼児の発育は個人差が大きいです、このグラフを一応の目安としてください。なお、2歳未満の身長は寝かせて測り、2歳以上の身長は立たせて測ったものです。

<https://www.mhlw.go.jp/content/11908000/000440915.pdf>

母子健康手帳に記載される「発育曲線」


- ・ 網掛けの下側の線が3パーセンタイル値、
- ・ 上側が97パーセンタイル値
- ・ 網掛けの範囲に「全体の94%の子どもが入る」
- ・ 3歳の女兒の身長は86cm～99cmの範囲が94%
- ・ これより、低いと注意、といった使い方

発育について実際は、一回で評価するのではなく変化をプロットしてから評価しますが

- ・ なぜ使う？
- ・ 真ん中あたりより、両端に注目している
- ・ 正規分布（山型で左右対称）からずれている
- ・ 分かりやすい？


2変数を組み合わせた記述

- 量的データと量的データ
 - 散布図, 相関係数, 回帰直線
- 質的データと質的データ
 - クロス集計表
 - 疫学データなら相対危険や寄与危険



奇形出現	サリドマイド服用		合計
	あり	なし	
あり (ケース)	90 80.4%	22 19.6%	112
なし (コントロール)	2 1.1%	186 98.9%	188

散布図（相関係数， 回帰直線）



- X軸とY軸の変数の値で， ケースを図上にプロット
→ 散布図
- 直線的な関連が見て取れれば， 直線を引く
→ 回帰直線
- 2つの変数の関連の強弱は相関係数で評価する
- こちらも演習で

(ピアソンの) 相関係数


- 2つの変数の関連の強さを-1~+1で評価するための指標
- 正負と大きさを合わせて評価する

相関係数の大きさ	評価
0.0 ~ 0.2	ほとんど相関がない
0.2 ~ 0.4	やや相関がある
0.4 ~ 0.7	かなり相関がある
0.7 ~ 1.0	強い相関がある

分野によっては評価が異なるので注意！

相関係数の注意点①

- 一方の変数が増加(減少)すれば、他方の変数も増加(減少)する直線的な関係の強さを測る指標
- 外れ値の影響を強く受ける
- 非線形(直線的でない)関係の強さは測ることができない



相関係数の注意点②

- 2つの変数の間に直接的な相関関係がなくても、お互いに別の第3の変数による影響を受けて見かけ上の相関が生じる場合がある

例) アイスクリームとビールの売上には強い正の相関がある
→気温という第3の変数によって両方影響を受ける！

- 相関関係と因果関係は別概念


回帰分析

- 2つの変数 X, Y が直線の関係

$$Y = \beta_0 + \beta_1 X$$

X を説明 (独立)変数, Y を目的(従属)変数

- X が1単位変化すると Y が β_1 だけ変化する
- 平均への回帰
平均より身長が高い両親の子供は両親ほど身長が高くない



クロス集計表（分割表）

- XとYがそれぞれm, nカテゴリーの質的変数
→ ケースをXとYの値の組み合わせ毎に数え上げて表にする
「**m × n**クロス集計表」
- クロス集計表の作成とXYの関連の検討は演習で

		Y				
		1	2		n	計
X	1					
	2					
	m					
	計					

本日の復習1

- (1) 患者を正しく陽性と判定できる確率が99%，患者でない場合も99%正しく陰性と判定できる検査でも，実際に集団検診で利用すると，陽性になった人の中に患者は数%しか存在しないことがあります。なぜ，こんな事になるのか，簡単に説明して下さい。
- (2) コインを4回投げて，4回とも同じ面が出現する確率を計算しなさい。

本日の復習2

(3) 25人の体重 (kg) のデータを示す。平均値と中央値を求めよ。

39
42 44
47 48
50 51 54 54
56 57 57 58
60 61 61 62 63 64
66 67 67 69
70 73

(4) 検診を受診した100人の年齢と血清尿酸値との関係について、情報量を保持したまま図示する際に用いるのはどれか。

1. 散布図 2. 帯グラフ 3. 棒グラフ 4. ヒストグラム