

情報科学演習 第 11,12 回 2026/09/24

「表計算(3) Excel による記述統計 1」

到達目標：数値による要約やグラフによる 1 変数の記述統計を実践できる

「表計算(4) Excel による記述統計 2」

到達目標：数値による要約やグラフによる 2 変数の記述統計を実践できる

テキスト：12 章

【準備】<https://y-okada-glitch.github.io> から、ファイル「エクセル演習 02.xlsx」をダウンロードすること

0. 記述統計の復習

記述統計とは、集めたデータを、表・グラフ・数値で整理して母集団の特徴を把握するための方法。

1) データの種類

量的データ（数値として計算・比較ができるデータ）

- 比尺度

特徴：「0」が「何も存在しない（絶対ゼロ）」を意味し、足し引きだけでなく「〇倍」という掛け算・割り算が成り立ちます。例：体重（60 kg は 30 kg の 2 倍）、尿量、投与量など。

- 間隔尺度

特徴：値の「差（引き算）」には意味がありますが、「0」が「無」を意味しないため、「〇倍」という計算は成立しません。例：体温（38℃は 36℃より 2℃高い）、西暦、時刻など。

質的データ（数値ではない分類や順番を表すデータ）

- 順序尺度

特徴：項目間に「順番」や「症状の強弱」は存在しますが、項目同士の間隔（差）が均等とは限らず、数値計算はできません。例：尿蛋白（－、±、＋、++）、疼痛の度合い（軽度・中等度・高度）など。

- 名義尺度

特徴：単に区別や分類をするための名前（ラベル）であり、順番や計算の意味は一切ありません。例：血液型（A・B・O・AB）、性別など。

2) 表とグラフでデータの分布を確認する

分布とは、集めたデータがどの値に集中しているか、またどれくらい散らばっているかという全体の偏りや形のこと。

データの種類	図・表
量的データ	度数分布表、棒グラフ、円グラフ、帯グラフ
質的データ	ヒストグラム

3) 分布の中心を確認する

例：5 人の待ち時間 5、10、10、15、60 分

代表値	計算方法	例の場合
平均値	標本の総和を標本数で割る	$100/5=20$ 分
中央値	小さい順に並べて	10 分
最頻値	最も多く出てくる値	10 分

- ・ 平均値は極端な値の影響を受けやすい。
- ・ 量的データの場合、最頻値は最多の階級の中央値

4) 分布のばらつきの大きさを確認する

- ・ 偏差：各標本－平均値
全ての標本の偏差を足すと 0 になる
- ・ (標本) 分散：全ての標本の偏差を二乗して足して、標本数で割ったもの
全ての標本の偏差を足すと 0 になるので、二乗することで、平均の周りに対するばらつきの指標。大きいほど、ばらつきが大きい。
- ・ 標本標準偏差： $\sqrt{\text{分散}}$
分散は単位も二乗するため、平方根を取ることで、比較しやすくしたもの。

5) パーセンタイル

パーセンタイルとは、小さい方から数えて、ある割合の位置にある値。

四分位数

最小値	第 1 四分位数	第 2 四分位数	第 3 四分位数	最大値
最も小さい標本	25%の位置	50%の位置	75%の位置	最も大きい標本

- ・ 四分位範囲＝第 3 四分位数－第 1 四分位数。
- ・ 範囲＝最大値－最小値

6) 2 変数間の関係を確認する


組み合わせ	表・グラフ
質的×質的 例：喫煙の有無 × 飲酒の有無	クロス（集計）表 組み合わせごとの人数を数える
量的 × 量的 例：身長 × 体重	散布図 1 人を 1 つの点で表す

- ・ 相関係数：直線的な関係の向きと強さを、 $-1 \sim +1$ で表します。
 ± 1 に近いほど関連が強い。0 に近いほど直線的な関係は弱い。
- ・ 回帰直線：散布図の傾向を 1 本の直線で表す。予測にも使います。
- ・ 相関係数は外れ値（他から大きく離れた値）の影響を受けます。

次のページから、Excel で表・グラフ・数値を実際に求めましょう。

1. グラフの基本

シート「グラフ練習」で基本的なグラフ作成方法を演習する。グラフ作成の基本的手順は「グラフの元になるセル範囲を系列・項目名も含めて選択」して、メニューの「挿入」,「グラフ」で適切な種類のグラフを選んで、おおよその形を作成する（グラフの種類は後からも簡単に変更可能）。その後、シート内の見本を参考に細かい仕上げを行って、グラフとして完成させる。



死亡数		
	男	女
胃	30,809	15,870
肝	19,008	9,881
膵	16,186	15,680
肺	53,208	21,170
大腸	26,818	22,881
乳房		13,584
子宮		6,429
その他	73,479	45,343
計	219,508	150,838



コラム：ちゃんとしたグラフに最低限必要なこと

- ・何のグラフかを示す「**タイトル**」
- ・縦と横の軸が何を示すかという「**軸ラベル**」（数値の場合は単位も必須）
- ・グラフの系列もしくは項目を説明するための「**凡例**」もしくは「**データラベル**」
- ・データが引用されたものであれば、**出典（URL や書誌情報など）**を明記

1) 円グラフ

データ範囲（右図参照）を選択します。作図するデータ以外に、円グラフの場合は系列名（この場合は”死亡数”）と項目名（この場合は各部位の名称）も選択します。メニューの「挿入」「グラフ」でグラフの種類を選択します。

作成されたグラフは、グラフエリア（グラフ全体の枠）をドラッグして位置やサイズの変更が可能です。





メニューの「グラフのデザイン（グラフを選択していないと表示されない）」の「クイックレイアウト」や「グラフスタイル」でおおよそ意図したグラフに仕上げることができる。


細かい調整は、グラフ上の調整したいところで右クリックして「XXXの書式設定」で行える。また、「グラフ要素の追加」で表示されていない要素を追加することもできる。

2) 棒グラフ

棒グラフは、横棒グラフと縦棒グラフが作図できる（向きが異なるだけで基本的には同じ）。性別・部位別悪性新生物死亡数のデータで作成してみよう。普通の棒グラフ（左下、集合縦棒）で実際の数を比較する方法と、帯グラフ（右下、100%積み上げ横棒）で割合を比較する方法は、表現の目的に応じて選べば良い。



帯グラフの場合は、「グラフ要素を追加」で「線」「区分線」を追加しておく、と、比較が分かりやすくなる。



3) 散布図


散布図は X と Y に相当するデータ系列を範囲選択して作図する。散布図は目盛のとり方（縦横の比）で印象が左右されやすいので注意する。グラフエリアのサイズ変更で調整すると共に、XYそれぞれの「軸の書式設定」で軸の最小値と最大値を必要に応じて調整する。特に“理論上取り得ない範囲まで軸を広げない”のは重要なポイントである（例えば、割合の上限が 100%なら軸の目盛も 100%までとする、など）。

4) 散布図 2（項目軸が数値の場合、折れ線グラフの代わりに）

“肺炎と脳血管疾患死亡率（人口 10 万対）の年次

推移”を折れ線グラフとして作成する場合、グラフの種類を折れ線グラフとして作図すると右のように、年の間隔が変化するため、推移を示すグラフとしては不適切である（2010 年以降の横軸上の間隔が異なっている）。

この様に、形式として折れ線グラフではあるが、横軸が数値（年や物理量など）である場合、散布図（直線または直線とマーカー）でして描くと、横軸の間隔が適切に作図される。



※他にも多くの種類のグラフが作成できるが、個別に詳しい解説はしない。

2. 絶対参照（絶対指定）（セル番地の固定）

シート「絶対参照」で確認する。

度数分布表で、度数の隣に相対度数（%）を計算する。血清総コレステロール値（mg/dL）が 130 以上 140 未満の階級の相対度数は、度数 1 を合計の度数 50 で割ったものだが、他のセルに入っている数値を式に直接入力することは好ましくないの、セル番地を使った式で表現する。とりあえず D3 セルは “=C3/C13” で計算できる（セルの書式設定で「パーセンテージ」を指定）。この式を D4 から D13 セルの範囲にコピー&ペーストしよう。結果はどうなっているだろうか。

普通にセル番地を式で使うと、貼り付けられた位置に対応して式中のセル番地が変化する。これを**相対参照**（要するに“1 つ左のセルと、2 つ左のセルを足す”とった形で式が解釈される）と呼ぶ。横や縦方向に同じ計算式を繰り返す処理には便利だが、今回のように度数の“計”をすべての計算式で使いたい場合には不便である（50 と数値を直接式に記入するのは論外）。

ここで有効なのがセル番地の固定（**絶対参照**）、テキストでは絶対指定という方法である。貼り付けによって変化しては困るセル番地の行や列に“\$”を付ければ、コピー&ペーストによっても変化しない。ここでは D3 セルを “=C3/C\$13” と C13 セルの行番号のみを固定しよう（\$C\$13 でも結果は同じだが不要な固定はしない方が良い）。これを再度 D4 から D13 セルに貼り付けてどうなるか確認してみよう。

なお、キーボードから“\$”を入力する以外に、セル番地入力（選択）中に F4 キーを押すと、セル番地の各種参照法が指定できる。

理解できたら、血液型の相対度数を H16 セルに適切な計算式を入力し、それを I16 から L16 セルにコピー&ペーストとして、相対度数を計算しよう。

・ 前回（+絶対参照）の復習

シート「主要死因の推移」で演習を行う。これは人口動態統計の死因別死亡数のデータを国勢調査年のみに限定して、e-stat（<https://www.e-stat.go.jp/>）からダウンロードしたデータである。死因については、5 大死因のみを個別に扱い、他の死因は“その他”とまとめることとする。

【練習】 次のステップで、表とグラフを完成させよう。

- 1) 死因“その他”の死亡数を計算せよ。

ヒント：その他は総数から悪性新生物～老衰の合計を引いたものである。合計を求めるには関数「sum(範囲)」を使う。

- 2) 死亡率（人口 10 万対）を計算せよ。なお、値は整数表記で良い。

ヒント：人口で割ると人口 1 対なので、人口 10 万対にするには…。また、その年の人口については列を固定しないとコピー&ペーストがうまくいかない。

- 3) 各死因が総死亡に占める割合を計算し、パーセント（小数点以下 1 位表示）で表示せよ。

- 4) “その他”を除く 5 大死因の死亡率（人口 10 万対）の年次推移のグラフを作成する。

ヒント：年が等間隔なので折れ線グラフでも不都合はないが、散布図で作成することが望ましい。また、年の列と死亡率の列が離れているので、範囲選択の方法に注意（前回参照）。

3. 記述統計の実践

シート「記述統計演習」に切り替えよう。

・ 前回の復習

【練習】データの準備を兼ね、IF 関数を利用して高血圧の判定をしよう。

最高血圧と最低血圧の値から、高血圧の判定を行う。細かい区分ではなく、[最高血圧 140mmHg 以上、かつ／または、最低血圧 90mmHg 以上] を“高血圧”，この条件を満たさない場合は“正常域血圧”と判定しよう（細かい区分は“高血圧学会 高血圧 基準”などで検索して確認）。IF 関数を入れ子にする（ネストする）必要があるが、左列の BMI 判定の式を参考にしてほしい。

・ 1 変数の記述統計 （情報科学第 11、12 回講義資料も必要に応じ参照）

1) 関数による集計

関数を使って平均値などを計算しよう。シートの 103 行以降に、それぞれの列について、平均値、標準偏差、最大値、最小値、中央値を計算するセルを用意している。次の表と実演を参考に関数を使って値を求めよう。”年齢”にだけ式を入力し、他の列へはコピー&ペーストしよう。

機能	関数名	引数	注意
算術平均 (平均値)	average	(範囲) 範囲ではなく(数値 1,数値 2,..., 数値 n) と列挙する方法もある がまず利用しない	数値以外のデータや空白は無視される (以下、共通)
標準偏差	stdev.s	〃	不偏分散 (n-1 で割った方) の平方根
中央値	median	〃	
最頻値	mode	〃	同一値の頻度を求めるため、量的データではしばしばエラーに
最大値	max	〃	
最小値	min	〃	
パーセンタイル	percentile.exc	(範囲 ,p)	p×100 パーセンタイルを求める 若干異なる方法 (percentile.inc) も
データの個数	count	(範囲)	範囲に含まれる「数値」の個数を求める ※空白でない(文字やエラーの)セルも 数える counta 関数があります

計算式、関数を利用した際に出現することがある代表的なエラーを表に整理する。

表示	意味, 原因の例
#NAME?	関数名が不明。たぶんスペルミス
#NUM!	数値が不適切。例えば負の値の平方根を求めようとしている。
#N/A	処理対象のデータがない、または処理できない。
#DIV/0!	計算式中で“0 で割る”を行った。
#VALUE!	引数の形式が不適切。例えば、文字列を計算させようとしている。

2) ピボットテーブルの使用

エクセルでデータ分析を行う際に、便利な機能としてピボットテーブルが利用できる。様々な

使い方ができる反面、細かい機能を理解するのは難しい。ここでは、基本的な操作を演習しよう。

ピボットテーブルの作成は、項目名も含んだ表全体を範囲選択し、「挿入」、「ピボットテーブル」から、配置する場所は「新規ワークシート」にするのが簡単だろう。

ID	年齢 (歳)	身長 (cm)	体重 (kg)	最高血圧 (mmHg)	最低血圧 (mmHg)	BMI	BMI判定	高血圧判定
85	59	149.1	48.0	104	70	21.6	正常	正常
86	58	147.2	53.8	158	98	24.8	正常	高血圧
87	49	156.0	52.8	134	76	21.7	正常	正常
88	57	149.6	53.2	130	82	23.8	正常	正常
89	49	150.7	61.6	130	80	27.1	肥満	正常
90	51	152.4	51.8	128	76	22.3	正常	正常
91	54	150.8	55.2	122	70	24.3	正常	正常
92	45	157.7	65.2	170	108	26.2	肥満	高血圧
93	59	152.8	49.8	136	84	21.3	正常	正常
94	59	152.5	49.2	150	88	21.2	正常	高血圧
95	58	149.6	59.0	148	88	26.4	肥満	高血圧
96	52	144.5	56.8	146	90	27.2	肥満	高血圧
97	52	151.3	48.6	140	90	21.2	正常	高血圧
98	58	147.0	51.2	150	88	23.7	正常	高血圧
99	47	159.7	53.2	102	72	20.9	正常	正常
100	46	152.6	50.0	136	78	21.5	正常	正常

新規作成されたピボットテーブルのシートには、テーブルの設定を行う部分と作成されたテーブルが表示される部分がある。

2)-1 度数分布表の作成

行ラベル	データの個数 / BMI判定
るい瘦	5
正常	70
肥満	25
総計	100

項目（変数）名をボックスにドラッグし、表についての設定を「行」と「値」の両方のボックスに入れたところと、作成された表である。

この表は“BMI 判定”の度数分布表となっている。質的データの場合（または取り得る値の少ない離散量の場合）はこれで良いが、連続量の場合はこの手順だけではうまくいかない。

今度は，“年齢(歳)”を同じようにボックスに入れて（“BMI 判定”は取り除くこと）どのように表示されるか確認しよう。



行ラベル	合計 / 年齢 (歳)
40	80
41	82
42	84
44	44
45	225
46	128

先ほどは各判定の度数（個数）が表示されていたが、今度は年齢の合計が表示されている。また、各年齢の値毎に行が分けられている。この2つの点（合計が表示される点と各歳の値毎に集計されている点）を修正しよう。

まず、ボックスの“値”が「合計 / 年齢（歳）」となっているが、ここをクリックし、「値フィールドの設定」を選択、集計方法で「個数」を選択する。

次に、度数分布表の作成における“階級の作成”と同じ作業が必要になる。そのためには、連続量を区切って階級とするために次の操作を行う。

作成されたテーブルの“行ラベル”のどれかの値の上で右クリックし、メニューから「グループ化」を選択する。グループ化の指定では、値の最小と最大が自動で表示されているが、最低（先頭の値）が区切りが悪い数値の場合は自分で修正し、「単位」に階級の幅を指定する。




行ラベル	個数 / 年齢（歳）
40-44	7
45-49	21
50-54	32
55-59	40
総計	100

これで連続量の度数分布表が作成できた。表としての仕上げは、ピボットテーブル自体に施すのではなく、テーブルをどこか適切な場所にコピー&ペースト（“値”で貼り付けることが望ましい）してから行えばよい。

2)-2 平均などの集計

先ほどの「値フィールドの設定」を使えば、平均値や標準偏差などが計算できる。ただし、求めるものの個数だけ、値ボックスに変数名を入れる必要はある。

また、“行”のボックスにグループ分けを行う変数（ここでは BMI 判定や高血圧判定が該当）を指定すると、グループ毎の集計が可能である。なお、下記図中の“標本標準偏差”は“不偏分散の平方根”の方である。



行ラベル	平均 / BMI	標本標準偏差 / BMI2
高血圧	24.45206667	3.455130444
正常	22.53172743	2.730717421
総計	23.28065973	3.160329721


※ピボットテーブルでは、計算式の場合と異なり（通常は）もとのデータが更新されても、テーブルは自動的に更新されることがない。テーブル上で右クリックメニューから「更新」を指定すれば新しいデータが反映される。

・2 変数の記述統計

1) 相関と回帰

ピアソンの積率相関係数は関数 `correl` で求める。引数は X の範囲と Y の範囲の 2 つの範囲である。例えば、身長と体重の相関係数を求めるには、`=CORREL(C2:C101,D2:D101)` と入力する。情報科学では詳しく触れていないが、順位相関係数（スピアマンの順位相関係数）を計算するには、データを `rank.avg` 関数で順位に変換したものに `correl` 関数を利用すればよい。


また、回帰直線はグラフの散布図で求めることができる。例えば、身長から体重への回帰直線を求めるには、身長を横軸、体重を縦軸として散布図を作成する。散布図のプロットされた点の上で右クリックメニューを表示させると「近似曲線の追加」が選べる。「線型近似」のままで、「グラフに数式を表示する」と回帰直線の式が表示される。また、「グラフに R-2 乗値を表示する」で、相関係数の二乗（決定係数とも呼ぶ）を表示することができる。




ここでは、回帰直線は 体重 $\text{kg} = 0.54 \times \text{身長 cm} - 27.6$ となった。この式を使うと、例えば身長 150cm なら体重は 53.4kg と予測される。

2) クロス集計表

ピボットテーブルの機能で、クロス集計表を作成する。クロス表の行と列の項目をそれぞれ行と列のボックスにドラッグする。「値」はどちらの項目でもかまわない。値は「個数」であることを確認しておく。






データの個数 / 高血圧判定	列ラベル		
行ラベル	高血圧	正常域血圧	総計
るい瘦	1	4	5
正常	23	47	70
肥満	15	10	25
総計	39	61	100

クロス表の仕上げは、これまでと同様にコピー&ペーストして、別のところで行う。

※グループ別の平均値などの集計は 1 変数の記述で既に説明したが、同様に行にグループ分けする変数を指定すると、連続量の場合のグループ別の度数分布表も簡単に作成することができる。

3) 「データ分析」を使った場合

統計手法が限られているが（一部は次回に演習予定）、統計関連のひとまとまりの作業を行ってくれる機能も用意されている。「データ」の中の「データ分析」を選択すると、アドインである分析ツールが利用できる（メニューにない場合はオプションから設定する必要がある）。分析ツールでは、度数分布表の作成とヒストグラムの描画、基本的な検定（t 検定、F 検定等）などを対話型でデータ範囲等の指定を行うことで実行できる。



コラム：他の方法

集計にあたって、他の方法も色々考えられる。

例えば、使い方は難しいが便利な関数として countif 関数がある。引数は“調べる範囲”と“条件”の 2 つで、例えば BMI 判定で肥満の数を調べるなら =countif(H2:H101,”肥満”) でよい。条件は””で囲む必要があり、例えば数値で BMI の値が 25 以上をカウントする場合の条件なら”>=25”とすればよい（条件が他のセルに入っているならセル番地だが）。

さらに肥満なら 10、そうでなければ 0、高血圧なら 1、そうでなければ 0 として、その値を合計すると、両方に該当すれば 11、片方なら 10 または 1、両方該当しなければ 0 という値を持つので、この 4 つのパターンをカウントすれば、クロス集計表となる。また、同様なテクニックで度数分布表を作成することもできる。

他にも複雑な関数（例えば複数の条件を組み合わせる countifs という関数などもある）を利用する方法がいろいろ考えられる。さほど推奨するものではないが、ピボットテーブルのようにマウスによる煩雑な操作の繰り返しが必要でないと、データの変更に対応してリアルタイムで結果が更新されるといったメリットがある方法である。

以上